



Taller 2 - Redes Neuronales

Dayanna Alexandra Garzon Linares

Brenda Natalia Rojas Montenegro

Christopher Alexander Vivas Alvarado

FREDY ALEXANDER ORJUELA LOPEZ

Docente

Sistemas Avanzados

Facultad De Ingeniería

Ingeniería Industrial

Bogotá, 2026

Índice

Introducción.....	3
Fase 1: Desarrollo Analítico: Regularización Ridge.....	5
Representación Vectorial.....	5
Expansión de la Forma Cuadrática.....	6
Condición de Primer Orden.....	6
Solución Cerrada.....	7
Preguntas.....	7
Fase 2: Optimización Numérica y Descenso de Gradiente.....	8
Modelo Base.....	8
Impacto de la Tasa de Aprendizaje (η).....	9
Learning rate en 0.5.....	9
Learning rate en 10^{-7}	10
Dependencia del Punto Inicial.....	11
Start point (0.6,-0.6).....	11
Preguntas.....	12
Fase 3: Redes Neuronales (MLP) y Ajuste de Hiperparametros.....	13
Evaluación de Métricas de Regresión.....	13
Preguntas.....	15
Fase 4: Redes Neuronales (MLP) y Ajuste de Hiperparametros.....	19
Propagación hacia Adelante (Forward Propagation) Manual.....	19
Puntaje de la Capa Oculta.....	19
Activación de la Capa Oculta.....	20
Puntaje de la Capa de Salida.....	20
Probabilidades de Clase.....	21
Preguntas.....	21
Fase 5: Evaluación de Modelos y Toma de Decisiones.....	22
El Desafío del Desbalance de Clases.....	22
Preguntas.....	23
Interpretación de la Matriz de Confusión.....	24
Tarea de Cálculo de Métricas.....	25
Preguntas.....	26
Conclusiones.....	27
Bibliografía.....	28

Introducción

En el presente trabajo se aborda el problema de la predicción y clasificación de la demanda de bicicletas, así como su relación con la toma de decisiones en contextos industriales. Inicialmente, se analiza la estimación de la demanda mediante modelos de regresión, permitiendo comprender el comportamiento de variables como temperatura, hora y condiciones externas sobre el uso del sistema de bicicletas. Posteriormente, se incorporan técnicas de optimización y redes neuronales para mejorar la capacidad predictiva y abordar problemas más complejos de clasificación.

Fase 1: Desarrollo Analítico: Regularización Ridge.

Representación Vectorial

Representación Vectorial

$$J(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$J(\beta) = \sum_{i=1}^n \left(y_i - \sum_{j=0}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$J(\beta) = \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Matriz

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

valor sólido

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Vector

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

Predicción

$$X\beta = \begin{bmatrix} x_1^T \beta \\ x_2^T \beta \\ \vdots \\ x_n^T \beta \end{bmatrix} \rightarrow Y - X\beta$$

$$\sum_{j=1}^p \beta_j^2 \rightarrow \beta^T \beta$$

$$J(\beta) = (Y - X\beta)^T (Y - X\beta) + \lambda \beta^T \beta$$

Expansión de la Forma Cuadrática

Expansión de Forma Cuadrática

$$J(\beta) = (Y - X\beta)^T(Y - X\beta) + \lambda \beta^T \beta$$

$$\textcircled{1} (Y - X\beta)^T(Y - X\beta)$$

$$= Y^T Y - Y^T X \beta - \beta^T X^T Y + \beta^T X^T X \beta$$

$$\textcircled{2} = Y^T Y - (\beta^T X^T Y) - \beta^T X^T Y + \beta^T X^T X \beta$$

$$= Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta$$

$$\textcircled{3} J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta + \lambda \beta^T \beta$$

$$\textcircled{4} J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T (X^T X + \lambda I) \beta$$

Condición de Primer Orden

Condición Primer Orden

$$\begin{aligned} \frac{\partial J(\beta)}{\partial \beta} &= \cancel{Y^T Y} - 2\beta^T X^T Y + \beta^T (X^T X + \lambda I) \beta \\ &= -2\beta^T X^T Y + \beta^T (X^T X + \lambda I) \beta \\ &= -2X^T Y + \beta^T (X^T X + \lambda I) \beta \end{aligned}$$

$$\Rightarrow \beta^T (X^T X + \lambda I) \beta$$

Regla de derivación revisando que la matriz es simétrica

$$\frac{\partial}{\partial \beta} (\beta^T A \beta) = 2 A \beta$$

$$\Rightarrow \frac{\partial}{\partial \beta} (\beta^T (X^T X + \lambda I) \beta) = 2(X^T X + \lambda I) \beta$$

$$\Rightarrow \frac{\partial J(\beta)}{\partial \beta} = -2X^T Y + 2(X^T X + \lambda I) \beta$$

$$-2X^T Y + 2(X^T X + \lambda I) \beta = 0$$

$$(X^T X + \lambda I) \beta = X^T Y$$

Solución Cerrada

3)

Solución Cerrada

$$(X^T X + I\lambda)\beta = X^T Y$$

→ Ecuación lineal en Matriz

β = Vector

$$A = (X^T X + I\lambda)$$
$$C = X^T Y$$
$$A\beta = C \rightarrow \text{se multiplica con la inversa de } A$$
$$A^{-1}(A\beta) = (C)A^{-1}$$
$$A^{-1}\beta = A^{-1}C$$
$$\rightarrow \hat{\beta}_{\text{ridge}} = (X^T X + I\lambda)^{-1} X^T Y$$

Preguntas

¿Por qué la suma de λI garantiza que la matriz resultante sea invertible incluso si $X^T X$ es singular (no invertible)?

Cuando tomas λI y se suma, los autovalores de λ aumentan lo que genera que la matriz resultante sea positiva donde es invertible. Lo que hace Ridge es que la matriz obtenida tenga una forma estable que la matriz original no lo es. En el caso, tenemos que $X^T X + \lambda I$ pueden ser cero y gira a que λI sea positiva o sea invertible.

¿Qué sucede con el modelo y sus coeficientes cuando $\lambda \rightarrow 0$?

Si XTX es invertible, se podría comprender como una regresión lineal clásica porque disminuye la regularización, baja el sesgo y puede subir la varianza. Si los datos tienen una correlación alta, aumenta el riesgo de sobreajuste, porque no hay penalización y los coeficientes pueden crecer mucho.


¿Qué ocurre cuando $\lambda \rightarrow \infty$?

El modelo pierde capacidad de aprendizaje y queda con alta rigidez. En términos de sesgo y varianza, el sesgo crece mucho y la varianza cae. El resultado es un modelo que tiende a sub-ajustar los datos, porque deja de capturar relaciones reales importantes.

Fase 2: Optimización Numérica y Descenso de Gradiente

Modelo Base

Ilustración 1. Descenso del Gradiente en 3D y Proyección en Curvas de Nivel en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Impacto de la Tasa de Aprendizaje (η)

Learning rate en 0.5

Ilustración 2. Descenso del Gradiente en 3D y Proyección en Curvas de Nivel con un Learning rate en 0.5 en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Al incrementar la tasa de aprendizaje a un valor de $\eta = 0.5$, la trayectoria del algoritmo de descenso del gradiente presenta saltos amplios y no sigue una pendiente descendente hacia el mínimo. El modelo no logra converger hacia el centro de las curvas de nivel, sino que presenta saltos demasiados altos que hace que se aleje del centro. Esto ocurre porque el tamaño del paso es excesivo, provocando que el algoritmo sobrepase el mínimo en cada iteración, impidiendo la convergencia hacia la solución óptima.

Learning rate en 10^{-7}

Ilustración 3. Descenso del Gradiente en 3D y Proyección en Curvas de Nivel con un Learning rate en 10^{-7} en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Al reducir la tasa de aprendizaje a un valor de $\eta = 10^{-7}$, el algoritmo de descenso del gradiente presenta una convergencia muy lenta. A partir de la visualización en 3D se observa que el punto apenas se desplaza sobre la superficie, mientras que en las curvas de nivel se evidencia que no se aproxima al centro del mínimo. Por lo tanto, el número de iteraciones de 1000 no es suficiente para alcanzar el mínimo, ya que el tamaño del paso es demasiado pequeño, lo que genera un proceso de optimización ineficiente.

Dependencia del Punto Inicial

Start point (0.6,-0.6)

Ilustración 4. Descenso del Gradiente en 3D y Proyección en Curvas de Nivel con un Start point (0.6,-0.6) en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Al modificar el punto inicial a (0.6, -0.6), se observa que el algoritmo de descenso del gradiente no converge necesariamente al mismo punto final que en otros experimentos. A partir de la visualización en 3D y en las curvas de nivel, se evidencia que la función presenta múltiples valles o mínimos locales, ya que existen varias regiones cerradas hacia las cuales puede dirigirse la trayectoria. El algoritmo converge hacia el mínimo más cercano dependiendo del punto inicial, lo que confirma que su comportamiento depende de la ubicación de la función y que no garantiza encontrar el mínimo global.

Preguntas

Explique físicamente que ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel?

El fenómeno de overshooting ocurre cuando la tasa de aprendizaje es demasiado alta, provocando que el tamaño del paso supere la distancia al mínimo. Como resultado, el algoritmo sobrepasa el punto óptimo en cada iteración, generando oscilaciones e impidiendo la convergencia. En las visualizaciones, esto se evidencia por trayectorias inestables que atraviesan las curvas de nivel sin dirigirse al centro del mínimo.

Si el algoritmo se detiene en la iteración 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje?

Si el algoritmo se detiene en la iteración 1000 y aún está lejos del mínimo, es más eficiente ajustar la tasa de aprendizaje en lugar de aumentar el número de iteraciones. Esto se debe a que una tasa de aprendizaje muy pequeña genera avances extremadamente lentos, por lo que incrementar las iteraciones solo incrementa el costo computacional sin mejorar significativamente la convergencia. Ajustar adecuadamente la tasa de aprendizaje permite alcanzar el mínimo en menos iteraciones, optimizando el tiempo de cómputo y la eficiencia del algoritmo.

En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un único punto de inicio aleatorio?


En problemas de ingeniería con múltiples variables es riesgoso usar un solo punto inicial aleatorio porque el resultado del descenso de gradiente depende de dónde empieza. La función puede tener varios mínimos y el algoritmo simplemente baja por el más cercano, no necesariamente el mejor. Esto significa que se puede obtener una solución que funciona, pero no es la óptima y puede generar mayores costos o ineficiencias. Por eso, es recomendable probar con varios puntos iniciales y comparar los resultados, para elegir la mejor solución posible.

Fase 3: Redes Neuronales (MLP) y Ajuste de Hiperparametros

Evaluación de Métricas de Regresión


Ejecuta el modelo MLP Regressor inicial con la configuración base (hidden layer sizes=(16, 8, 4)). Observe los resultados de las métricas MAE, RMSE y R2 tanto para el conjunto de entrenamiento como para el de prueba (test).

Ilustración 5. Modelo MLP Regresor en Diagrama de Dispersión en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 6. Modelo MLP Regresor en Histograma en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 7. Modelo MLP Regressor en Curva de Dispersión en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB

Preguntas

Explique la diferencia técnica entre el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). ¿Cuál de las dos penaliza con mayor severidad los errores grandes (outliers) en las ventas y por qué?

El MAE mide el error promedio en términos absolutos, otorgando el mismo peso a todos los errores, mientras que el RMSE eleva los errores al cuadrado antes de promediarlos (Victor A.Rico, 2022), lo que hace que los errores grandes tengan un impacto mucho mayor. Por esta razón, el RMSE penaliza con mayor severidad los outliers, ya que los errores grandes aumentan exponencialmente al ser elevados al cuadrado.


Si el R^2 en el conjunto de entrenamiento es significativamente mayor que en el de prueba, ¿qué fenómeno está ocurriendo? Proponga una solución basada en lo aprendido en la Fase 1 del taller.

Cuando el R^2 en entrenamiento es significativamente mayor que en prueba, se presenta un fenómeno de sobreajuste, donde el modelo se ajusta demasiado a los datos de entrenamiento y pierde capacidad de generalización. Una solución basada en la Fase 1 es aplicar regularización tipo Ridge (L2), que penaliza los coeficientes grandes y reduce la complejidad del modelo, mejorando su capacidad de generalizar a nuevos datos.

Al observar la gráfica de y_{real} vs y_{pred} , ¿se identifica algún patrón de error sistemático (ej. subestimación en ventas altas)?


A partir de la gráfica de y_{real} vs y_{pred} , se identifica un patrón de error sistemático en los valores altos, donde el modelo tiende a subestimar la demanda, ya que varios puntos se ubican por debajo de la línea diagonal. Esto indica que, aunque el modelo presenta un buen ajuste general, tiene dificultades para predecir correctamente las ventas más elevadas. Adicionalmente, el histograma de residuos muestra una distribución centrada en cero, pero con presencia de valores extremos, lo que sugiere la existencia de errores grandes en ciertos casos.

Ilustración 8. Modelo MLP Regresor Mejor en Curva de Dispersión en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 9. Modelo MLP Regresor Mejor en Histograma en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 10. Modelo MLP Regressor Mejor en Curva de Dispersión en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Fase 4: Redes Neuronales (MLP) y Ajuste de Hiperparametros

Propagación hacia Adelante (Forward Propagation) Manual

Puntaje de la Capa Oculta

✓

Puntaje Capa Oculta $\Rightarrow z^{(1)} = w^{(1)}x + b^{(1)}$

Neurona 1

$$z = 0,2(0,5) + 0,5(0,3) - 0,1(0,2) + 0,1$$
$$z = 0,1 + 0,15 - 0,02 + 0,1$$
$$z = 0,33$$

Neurona 2

$$z = 0,8(0,5) - 0,3(0,3) + 0,4(0,2) - 0,2$$
$$z = 0,4 - 0,09 + 0,08 - 0,2$$
$$z = 0,19$$

Neurona 3

$$z = -0,5(0,5) + 0,1(0,3) + 0,2(0,2)$$
$$z = -0,25 + 0,03 + 0,04$$
$$z = -0,18$$

Entonces

$$z^{(1)} = \begin{pmatrix} 0,33 \\ 0,19 \\ -0,18 \end{pmatrix}$$

Activación de la Capa Oculta

Activación Capa oculta

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$
$$\begin{aligned}\sigma(0,33) &\approx 0,582 \\ \sigma(0,19) &\approx 0,547 \\ \sigma(-0,18) &\approx 0,455\end{aligned}$$
$$A^{(1)} = \begin{pmatrix} 0,582 \\ 0,547 \\ 0,455 \end{pmatrix}$$

Puntaje de la Capa de Salida

Puntaje Capa Salida $z^{(2)} = w^{(2)} A^{(1)} + b^{(2)}$

Neurona 1

$$z = 0,5(0,582) - 0,4(0,547) + 0,1(0,455) - 0,2$$

$$z = 0,291 - 0,219 + 0,045 - 0,2$$

$$z = 0,0175$$

Neurona 2

$$z = 0,2(0,582) + 0,8(0,547) - 0,5(0,455) + 0,2$$

$$z = 0,116 + 0,438 - 0,2275 + 0,2$$

$$z = 0,5265$$

Neurona 3

$$z = -0,1(0,582) + 0,3(0,547) + 0,7(0,455) + 0,1$$

$$z = -0,058 + 0,164 + 0,3185 + 0,1$$

$$z = 0,5245$$

$$z^{(2)} = \begin{pmatrix} 0,0175 \\ 0,5265 \\ 0,5245 \end{pmatrix}$$

Probabilidades de Clase

Probabilidades Clase A⁽²⁾
Exponenciales

$e^{0,0175} \approx 1,018$
 $e^{0,5265} \approx 1,693$
 $e^{0,5245} \approx 1,689$

$\sum e^{z_j} = 1,018 + 1,693 + 1,689 = 4,400$

$P_1 = \frac{1,018}{4,400} \approx 0,231$
 $P_2 = \frac{1,693}{4,400} \approx 0,385$
 $P_3 = \frac{0,384}{4,400}$

$P = \begin{pmatrix} 0,231 \\ 0,385 \\ 0,384 \end{pmatrix}$

Softmax = $\frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}}$

Preguntas

Según las probabilidades obtenidas, ¿en qué categoría clasifica la red a esta campaña publicitaria?

La red clasifica la campaña como Impacto Medio (C2), ya que esta categoría presenta la mayor probabilidad (0.385). Sin embargo, se observa que las probabilidades de C2 y C3 son muy cercanas, lo que indica cierta incertidumbre del modelo entre impacto medio y alto.

¿Por qué utilizamos Softmax en la última capa en lugar de una función lineal o una simple sigmoide?

Se utiliza la función Softmax en la capa de salida porque transforma los valores en probabilidades que suman 1, permitiendo interpretar el resultado como una clasificación entre múltiples clases. A diferencia de una función lineal, Softmax garantiza una distribución probabilística donde cada salida representa la probabilidad de pertenecer a una clase específica.


¿Qué sucedería con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

Si todos los vectores de sesgo (b) fueran cero, la red perdería flexibilidad, ya que las neuronas dependerían únicamente de las combinaciones lineales de las entradas. Esto limitaría la capacidad del modelo para ajustarse correctamente a los datos, reduciendo su capacidad de representación y afectando negativamente el desempeño del modelo.

Fase 5: Evaluación de Modelos y Toma de Decisiones


El Desafío del Desbalance de Clases

Ilustración 11. Gráfica de Distribución de Clases de No Falla o Falle en Colab.




Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 12. Diagrama de Distribución de Temperaturas en Aire y Proceso en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 13. Matriz de Confusión (Random Forest) en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Preguntas

Si el modelo indica que los errores en la Clase 1 (Fallo) pesarán aproximadamente 14.7 veces más que en la Clase 0, ¿qué intenta corregir el algoritmo al configurar el parámetro `class weight` durante el entrenamiento?


El parámetro `class_weight` busca corregir el desbalance extremo entre clases, donde la clase de fallos es mucho menos frecuente. Al asignar un peso aproximadamente 14.7 veces mayor a la Clase 1, el modelo penaliza mucho más los errores en fallos que en no fallos. Esto obliga al algoritmo a no ignorar la clase minoritaria y a mejorar su capacidad de detección de fallos, evitando que el modelo se sesgue hacia la clase mayoritaria.

Explique por qué en este caso un Accuracy del 95 % podría considerarse un resultado deficiente para la gestión de mantenimiento si el modelo no logra detectar los fallos reales.

Aunque el modelo presenta un accuracy muy alto (99.9%), esta métrica puede ser engañosa en problemas desbalanceados como el mantenimiento predictivo. En estos casos, un modelo podría obtener alta exactitud simplemente clasificando la mayoría de los casos como “no falla”. Sin embargo, lo realmente importante es la capacidad de detectar fallos (Clase 1), lo cual se mide mejor con métricas como el recall. En este caso, el modelo presenta un recall del 97% para la clase de fallos, lo que indica un buen desempeño. No obstante, el análisis demuestra que confiar únicamente en el accuracy puede llevar a conclusiones incorrectas si no se evalúan métricas específicas para la clase crítica.

Interpretación de la Matriz de Confusión

Ilustración 14. Matriz de Confusión (Red Neuronal) en Colab.



Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Ilustración 15. Reporte de clasificación (Red Neuronal) en Colab.

```
--- Reporte de Clasificación (Red Neuronal) ---
      precision    recall  f1-score   support

     0       1.00      1.00      1.00     1932
     1       1.00      0.97      0.99        68

 accuracy          1.00          1.00     2000
 macro avg          1.00      0.99      0.99     2000
 weighted avg          1.00      1.00      1.00     2000
```

Nota. Imagen hecha por los estudiantes y desarrollada en COLAB.

Tarea de Cálculo de Métricas

Handwritten calculations on a grid background:

Precision $\rightarrow \frac{TP}{TP+FP}$
 $= \frac{66}{66+0} = 1.00$

Recall $\rightarrow \frac{TP}{TP+FN}$
 $= \frac{66}{66+2} = 0.9706$

Costo total de Error $\rightarrow (FN * 5000.) + (FP * 200)$
 $= (2 * 5000.) + (0 * 200)$
 $= 10.000 \text{ USD}$

Con los datos afirmamos que el modelo puede detectar fallas de manera precisa y es confiable y el modelo logra detectar el 97,06% de las fallas reales que es algo bueno pero tiene un costo elevado en su operación.

Preguntas

En el contexto de evitar paradas de la crítica, ¿Prefiere usted un modelo con un Recall del 98 % pero una Precisión del 60 %, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

En el contexto de evitar paradas críticas, es preferible un modelo con alto recall (98%) aunque tenga menor precisión (60%). Esto se debe a que los falsos negativos generan un costo mucho mayor en comparación con los falsos positivos. Un modelo con alto recall minimiza los fallos no detectados, reduciendo significativamente el impacto económico y operativo. Por lo tanto, es más conveniente aceptar algunas falsas alarmas que no detectar fallos reales.

Observe la gráfica de loss (pérdida) y accuracy durante el entrenamiento. ¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

A partir del comportamiento típico de las curvas de pérdida, se puede considerar que 30 épocas son suficientes para que el modelo converja, ya que la pérdida disminuye rápidamente en las primeras iteraciones y luego se estabiliza. En cuanto al error de validación, inicialmente sigue la misma tendencia que el error de entrenamiento, pero posteriormente puede estabilizarse o incluso aumentar ligeramente, lo que indica que el modelo ha alcanzado su capacidad óptima y continuar entrenando podría generar sobreajuste.

Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

El uso de métricas avanzadas como el recall permite enfocar el modelo en la detección de eventos críticos, como los fallos en maquinaria, en lugar de solo maximizar la exactitud general. En un contexto industrial, esto transforma directamente la rentabilidad, ya que evita paradas no planificadas, reduce costos de mantenimiento correctivo y mejora la continuidad operativa. Como se observa en este caso, priorizar la detección de fallos permite minimizar pérdidas económicas significativas, demostrando que una correcta selección de métricas impacta directamente en la eficiencia y sostenibilidad del negocio.

Conclusiones

Se evidenció la importancia de seleccionar una arquitectura de red neuronal adecuada, así como de ajustar correctamente sus parámetros para lograr un equilibrio entre precisión y capacidad de generalización. Se demostró que modelos más complejos no siempre garantizan mejores resultados, y que el uso de técnicas como la regularización permite mejorar la estabilidad y evitar problemas como el sobreajuste.

Adicionalmente, se concluye que en entornos industriales no es suficiente evaluar modelos únicamente con métricas tradicionales como el accuracy. La inclusión de métricas avanzadas como el recall resulta fundamental,

especialmente en problemas críticos como la detección de fallos, donde no identificar un evento puede generar altos costos operativos.

Finalmente, el trabajo demuestra que la analítica de datos y el uso de redes neuronales no solo aportan valor técnico, sino que también tienen un impacto directo en la rentabilidad de las organizaciones, al permitir optimizar recursos, reducir riesgos y mejorar la toma de decisiones en sistemas productivos.

Bibliografía

Carolina, G. C. A. (2025, 30 julio). *Modelo predictivo de producción agrícola colombiana utilizando redes neuronales y sistemas neuro difusos*.
<https://repository.udistrital.edu.co/items/94838c27-7ae4-4db5-8ee2-c1b1653ad0c4>

Gonzales, F. (2023). Influencia de la selección de hiper-parámetros en el rendimiento de autoencoders para la detección de ataques en red. *Universidad de Granada*.
https://www.researchgate.net/profile/Antonio-Mora-5/publication/371001009_Influencia_de_la_seleccion_de_hiper-parametros_en_el_rendimiento_de_autoencoders_para_la_deteccion_de_ataques_en_red/links/646e2558cde97a39292d3b01/Influencia-de-la-seleccion-de-hiper-parametros-en-el-rendimiento-de-autoencoders-para-la-deteccion-de-ataques-en-red.pdf

Paredes, A. A., Ventura, R. J. A., & Silverio, G. A. A. (2024). Mejora en la clasificación de datos con desbalance de clases mediante una redistribución de clases por k-means. *XIKUA Boletín Científico de la Escuela Superior de Tlahuelilpan*, 12, 111-116.
<https://doi.org/10.29057/xikua.v12iespecial.12768>

Victor A.Rico. (2022, 16 junio). *Métricas para evaluar Modelos de Regresión. Error Cuadrático Medio (MSE y RMSE)* [Vídeo]. YouTube.
<https://www.youtube.com/watch?v=bIMmeNp32WY>